

Maschinelles Lernen – Theorie Wahrscheinlichkeit & Statistik

Prof. Dr. Rainer Stollhoff

- Wahrscheinlichkeitsrechnung
 - Zufallsvariable
 - Wahrscheinlichkeitsrechnung
 - Wahrscheinlichkeitsverteilung
- Statistik
 - Zusammenhang zweier Zufallsvariablen
 - Korrelation und Kausalität
 - Lineare Regression
 - Trendlinie
 - Verlustminimierung
 - Erklärte Varianz

Zufallsvariable

- Für noch unbeobachtete Ereignisse z.B. eines Merkmals kennen wir keinen Wert.
- Mathematisch können wir noch unbeobachtete Ereignisse als Variable beschreiben z.B. X oder A .
- Da der Wert der Variable nicht bekannt ist, sondern zufällig bei der Beobachtung festgelegt wird, sprechen wir von einer Zufallsvariable.
- Entscheidend für die mathematische Analyse, sind die möglichen Werte oder Ausprägungen der Zufallsvariable und die Wahrscheinlichkeiten, mit denen die einzelnen Ausprägungen realisiert werden.

Beispiel 1

Tab. 11.4 Präferenzen bezüglich Softdrinks

| Getränk | Material | | |
|-----------|----------|---------|-------|
| | Glas | Plastik | Summe |
| Coca-Cola | 501 | 110 | 611 |
| Pepsi | 203 | 186 | 389 |
| Summe | 704 | 296 | 1000 |

- Annahme: $P = \frac{\text{Anzahl der günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}$
- $P(\text{Coca-Cola}) =$
- $P(\text{Glas}) =$
- $P(\text{Coca-Cola und Glas}) =$

Wahrscheinlichkeitstheorie

1. Wahrscheinlichkeiten als relative Häufigkeiten (frequentistischer Ansatz)

$$P = \frac{\text{Anzahl der günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}$$

2. Wahrscheinlichkeiten als mathematische Objekte (axiomatischer Ansatz)

a) Wertebereich zwischen 0 und 1

$$0 \leq P \leq 1$$

$P=1$: Sicheres Ereignis und $P=0$: Unmögliches Ereignis

b) Additionssatz

$P(A \text{ oder } B) = P(A) + P(B)$ wenn $(A \text{ und } B)$ unmöglich

c) Unabhängigkeit

Gilt $P(A \text{ und } B) = P(B) \cdot P(A)$ dann heißen A und B **unabhängig**.

Beispiel 1

Tab. 11.4 Präferenzen bezüglich Softdrinks

| Getränk | Material | | |
|-----------|----------|---------|-------|
| | Glas | Plastik | Summe |
| Coca-Cola | 501 | 110 | 611 |
| Pepsi | 203 | 186 | 389 |
| Summe | 704 | 296 | 1000 |

- $P(\text{Coca-Cola} \mid \text{Glas}) =$
- $P(\text{Glas} \mid \text{Coca-Cola}) =$

Wahrscheinlichkeitstheorie

1. Wahrscheinlichkeiten als relative Häufigkeiten (frequentistischer Ansatz)

$$P = \frac{\text{Anzahl der günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}$$

2. Wahrscheinlichkeiten als mathematische Objekte (axiomatischer Ansatz)

a) Wertebereich zwischen 0 und 1

$$0 \leq P \leq 1$$

$P=1$: Sicheres Ereignis und $P=0$: Unmögliches Ereignis

b) Additionssatz

$P(A \text{ oder } B) = P(A) + P(B)$ wenn $(A \text{ und } B)$ unmöglich

c) Unabhängigkeit

Gilt $P(A \text{ und } B) = P(B) \cdot P(A)$ dann heißen A und B **unabhängig**.

d) bedingte Wahrscheinlichkeit

$$P(A|B) := \frac{P(A \text{ und } B)}{P(B)}$$

e) Multiplikationssatz

$$P(A \text{ und } B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

f) Satz von Bayes

$$P(A|B) = P(B|A) \cdot P(A)/P(B)$$

Beispiel 1

Tab. 11.4 Präferenzen bezüglich Softdrinks

| Getränk | Material | | |
|-----------|----------|---------|-------|
| | Glas | Plastik | Summe |
| Coca-Cola | 501 | 110 | 611 |
| Pepsi | 203 | 186 | 389 |
| Summe | 704 | 296 | 1000 |

- $P(\text{Coca-Cola} \mid \text{Glas}) =$
- $P(\text{Glas} \mid \text{Coca-Cola}) =$

Intuitive Wahrscheinlichkeiten

- Matthias ist 27 Jahre alt. Er ist Single und hatte bisher nur sporadisch feste Beziehungen. Er ist im Allgemeinen eher zurückhaltend und sorgfältig. Er interessiert sich nicht für Politik oder soziale Fragen und verwendet den größten Teil seiner Freizeit auf eines seiner vielen Hobbys, wie z. B. Computer, Modellbau und mathematische Denksportaufgaben.
- Matthias ist Teilnehmer einer Marktforschungsstudie unter Ingenieuren und Juristen.
- Ist Matthias eher Ingenieur oder Jurist?

Intuitive Wahrscheinlichkeiten

- Matthias ist 27 Jahre alt. Er ist Single und hatte bisher nur sporadisch feste Beziehungen. Er ist im Allgemeinen eher zurückhaltend und sorgfältig. Er interessiert sich nicht für Politik oder soziale Fragen und verwendet den größten Teil seiner Freizeit auf eines seiner vielen Hobbys, wie z. B. Computer, Modellbau und mathematische Denksportaufgaben.
- Matthias ist Teilnehmer einer von **1000** Teilnehmern einer Marktforschungsstudie unter **500** Ingenieuren und **500** Juristen.
- Ist Matthias eher Ingenieur oder Jurist?

Intuitive Wahrscheinlichkeiten

- Matthias ist 27 Jahre alt. Er ist Single und hatte bisher nur sporadisch feste Beziehungen. Er ist im Allgemeinen eher zurückhaltend und sorgfältig. Er interessiert sich nicht für Politik oder soziale Fragen und verwendet den größten Teil seiner Freizeit auf eines seiner vielen Hobbys, wie z. B. Computer, Modellbau und mathematische Denksportaufgaben.
- Matthias ist Teilnehmer einer von **1000** Teilnehmern einer Marktforschungsstudie unter **100** Ingenieuren und **900** Juristen.
- Ist Matthias eher Ingenieur oder Jurist?

Intuitive Wahrscheinlichkeiten

- Matthias ist 27 Jahre alt. Er ist Single und hatte bisher nur sporadisch feste Beziehungen. Er ist im Allgemeinen eher zurückhaltend und sorgfältig. Er interessiert sich nicht für Politik oder soziale Fragen und verwendet den größten Teil seiner Freizeit auf eines seiner vielen Hobbys, wie z. B. Computer, Modellbau und mathematische Denksportaufgaben.
- Matthias ist Teilnehmer einer von **1000** Teilnehmern einer Marktforschungsstudie unter **5** Ingenieuren und **995** Juristen.
- Ist Matthias eher Ingenieur oder Jurist?

Intuitive Wahrscheinlichkeiten

- Matthias ist 27 Jahre alt. Er ist Single und hatte bisher nur sporadisch feste Beziehungen. Er ist im Allgemeinen eher zurückhaltend und sorgfältig. Er interessiert sich nicht für Politik oder soziale Fragen und verwendet den größten Teil seiner Freizeit auf eines seiner vielen Hobbys, wie z. B. Computer, Modellbau und mathematische Denksportaufgaben.
- Matthias ist
 - einer von **1000** Teilnehmern einer Marktforschungsstudie unter **500** Ingenieuren und **500** Juristen.
 - einer von **1000** Teilnehmern einer Marktforschungsstudie unter **100** Ingenieuren und **900** Juristen.
 - einer von **1000** Teilnehmern einer Marktforschungsstudie unter **5** Ingenieuren und **995** Juristen.
- Ist Matthias eher Ingenieur oder Jurist?
- Diskutieren Sie in Kleingruppen, wie sich die Aufgabenstellung mit Hilfe der Bayes Formel mathematisch darstellen lässt.

Wahrscheinlichkeitstheorie

1. **Wahrscheinlichkeiten als relative Häufigkeiten
(frequentistischer Ansatz)**
2. **Wahrscheinlichkeiten als mathematische Objekte
(axiomatischer Ansatz)**
3. **Wahrscheinlichkeiten als Grad persönlicher Überzeugung
(bayesianischer Ansatz)**

$$P(\text{Modell} | \text{Daten}) \propto P(\text{Daten} | \text{Modell}) \cdot P(\text{Modell})$$

Posterior

Likelihood

Prior bzw.

A-priori-Wahrscheinlichkeit

Wahrscheinlichkeitsfunktion

- Eine Wahrscheinlichkeitsfunktion ordnet Ereignissen x_i einer diskreten Zufallsvariable eine Wahrscheinlichkeit $f(x_i)$ zu
 - Beispiel 1: Wahrscheinlichkeiten als relative Häufigkeiten

$$P = \frac{\text{Anzahl der günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}$$

- Beispiel 2: Zufallsexperimente - Wir werfen eine faire Münze
 - In 50% der Fälle erhalten wir Kopf: $P(\text{Kopf})=0,5$
 - In 50% der Fälle erhalten wir Zahl: $P(\text{Zahl})=0,5$
- Eine Verteilungsfunktion gibt für einen Wert X die Wahrscheinlichkeit an, einen Wert kleiner oder gleich X zu beobachten. $F(X) = \sum_{z \leq X} P(z)$

Münzwurf

- Wir werfen eine faire Münze
 - mit $p=50\%$ erhalten wir Kopf
 - mit $(1-p)=50\%$ erhalten wir Zahl
- Die Münzwürfe sind voneinander unabhängig
$$P(a,b) = P(a) \cdot P(b)$$
- Wie hoch ist bei n Wiederholungen die Wahrscheinlichkeit $f(x_i)$ für
 - X_0 = keinmal Kopf
 - X_1 = einmal Kopf
 - X_2 = zweimal Kopf

Binomialverteilung

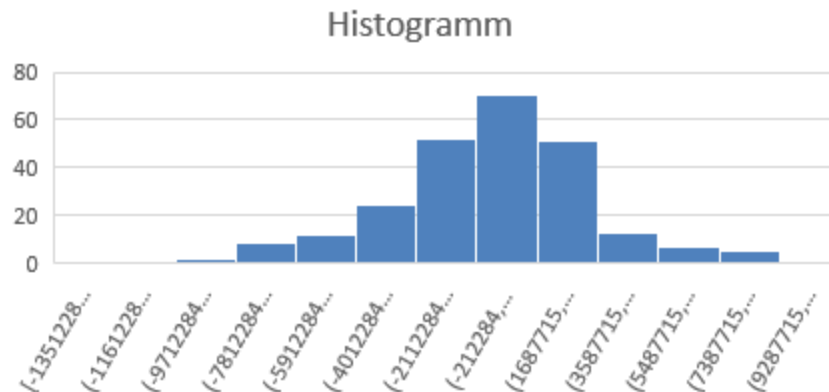
- Wir beobachten wiederholt ein Zufallseignis mit zwei möglichen Ergebnissen (0,1)
 - mit der Wahrscheinlichkeit p erhalten wir 1
 - mit der Wahrscheinlichkeit $(1-p)$ erhalten wir 0
- Die Wiederholungen sind voneinander unabhängig
$$P(a,b) = P(a) \cdot P(b)$$
- Wie hoch ist bei n Wiederholungen die Wahrscheinlichkeit $f(x_i)$ für
 - X_0 = keinmal 1
 - X_1 = einmal 1
 - X_2 = zweimal 1

Stetige Zufallsvariablen

- Stetige Zufallsvariablen sind nicht auf eine diskrete Auswahl begrenzt, sie können beliebige Zahlenwerte in einem zusammenhängenden Intervall annehmen
 - *Bsp: Wie lange warte ich auf die nächste S-Bahn?*
- Was ist ein Ereignis x_i ?
 - *Bsp: x_i = Wartezeit auf S-Bahn*
- Was ist die Wahrscheinlichkeitsfunktion $f(x_i)$?
 - *Bsp: $x_0 = 0$
 $x_1 = ?$
(x_i in Minuten, Sekunden, ms?)*

Diskretisierung stetiger Zufallsvariablen

- Bei einer Messung (spätestens bei der Digitalisierung) diskretisiert man stetige Variablen, d.h.
 - Man teilt den Wertebereich in eine endliche Anzahl von Intervallen auf
 - Anstelle der Messwerte speichert man das Intervall, in dem der Messwert liegt
- Ein Histogramm stellt die beobachteten Häufigkeiten als Säulendiagramm dar




- Aber: Jede Diskretisierung ist mit Verlust behaftet (vgl. Schallplatte vs. CD)

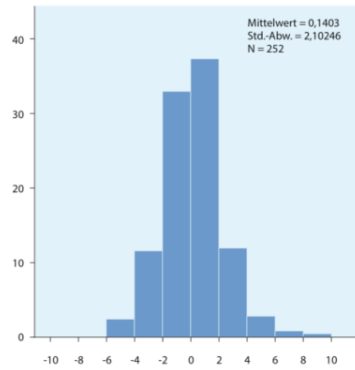
Histogramm und Dichtefunktion

- Wenn man für die Diskretisierung immer kleinere Intervalle wählt, wird aus dem Histogramm eine Dichtefunktion


Häufigkeitsprozent




Häufigkeitsprozent




Häufigkeitsprozent



Prozent




Dichte



Normalverteilung

Gauß'sche Glockenkurve

Erwartungswert μ



Normalverteilung

Gauß'sche Glockenkurve

GN4480100S8

Deutsche Bundesbank

Wolfgang Karl

Frankfurt am Main
1. September 1999



GN4480100S8

- Wahrscheinlichkeitsrechnung
 - Zufallsvariable
 - Wahrscheinlichkeitsrechnung
 - Wahrscheinlichkeitsverteilung
- Statistik
 - Zusammenhang zweier Zufallsvariablen
 - Korrelation und Kausalität
 - Lineare Regression
 - Trendlinie
 - Verlustminimierung
 - Erklärte Varianz

Wiederholung

- Was sind die Unterschiede zwischen Supervised und Unsupervised Learning?

Supervised Learning

- Erfahrung E
 - Input X
 - Outcome Y
- Aufgabe A
 - Vorhersage $\hat{Y} = A(X)$
- Qualität Q
 - Verlustfunktion $L(\hat{Y}, Y)$

Unsupervised Learning

- Erfahrung E
 - Input X
- Aufgabe A
 - Repräsentation $\hat{X} = A(X)$
- Qualität Q
 - von Repräsentationen $Q(\hat{X}_1, \hat{X}_2)$

Statistisches Lernen

- Wie lassen sich die Fragestellungen statistisch formulieren?

Supervised Learning

- Erfahrung E
 - Input X
 - Outcome Y
- Aufgabe A
 - Vorhersage $\hat{Y} = A(X)$
- Qualität Q
 - Verlustfunktion $L(\hat{Y}, Y)$

Unsupervised Learning

- Erfahrung E
 - Input X
- Aufgabe A
 - Repräsentation $\hat{X} = A(X)$
- Qualität Q
 - von Repräsentationen $Q(\hat{X}_1, \hat{X}_2)$

- Wahre Wahrscheinlichkeitsverteilungen
 - $P(X)$ und $P(Y)$: Randverteilungen
 - $P(X, Y)$: Gemeinsame Verteilung
 - $P(Y|X)$: Bedingte Verteilung
- Subjektive Schätzungen der Wahrscheinlichkeitsverteilungen
 - $\hat{P}(X)$ als Repräsentation von $P(X)$
 - $\hat{P}(Y|X)$ zur Vorhersage von Y als wahrscheinlichstem Outcome
- Lernen als Anpassen der Modelle an beobachtete Daten
 - $P(\text{Modell}|\text{Daten}) \propto P(\text{Daten}|\text{Modell}) \cdot P(\text{Modell})$

Zusammenhangsmaße

- Ein Zusammenhangsmaß gibt das Ausmaß des Zusammenhangs als Zahl an
- Ein einfaches Zusammenhangsmaß ist die Kovarianz:

$$\begin{aligned} &Cov(x, y) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \end{aligned}$$

- Sind x_i und y_i größer als der jeweilige Mittelwert \bar{x} bzw. \bar{y} dann steigt die Kovarianz
- Ist nur ein Wert größer und der andere kleiner, dann sinkt die Kovarianz

- Positiver Zusammenhang

| | | | |
|---|----|---|---|
| X | -1 | 0 | 1 |
| Y | -1 | 0 | 1 |

- Negativer Zusammenhang

| | | | |
|---|----|---|----|
| X | -1 | 0 | 1 |
| Y | 1 | 0 | -1 |

- Kein Zusammenhang

| | | | |
|---|----|---|---|
| X | -1 | 0 | 1 |
| Y | 1 | 0 | 1 |

Standardisiertes Zusammenhangsmaß

- Die Kovarianz wächst mit der Varianz der Variablen. Das erschwert die Vergleichbarkeit.
- Meist ist daher eine standardisierte Variante, der sog. Bravais-Pearson-Korrelationskoeffizient passender:

$$\rho_{x,y} = \frac{\text{Cov}(x,y)}{\sqrt{s^2(x) \cdot s^2(y)}} = \frac{\text{Cov}(x,y)}{s(x) \cdot s(y)}$$

- Die Werte des Korrelationskoeffizienten liegen dann bei
 - +1 für einen perfekt positiven Zusammenhang, z.B. $\rho_{x,x}$
 - 1 für einen perfekt negativen Zusammenhang, z.B. $\rho_{x,-x}$
 - 0 für keinen Zusammenhang, z.B. x und y unabhängig

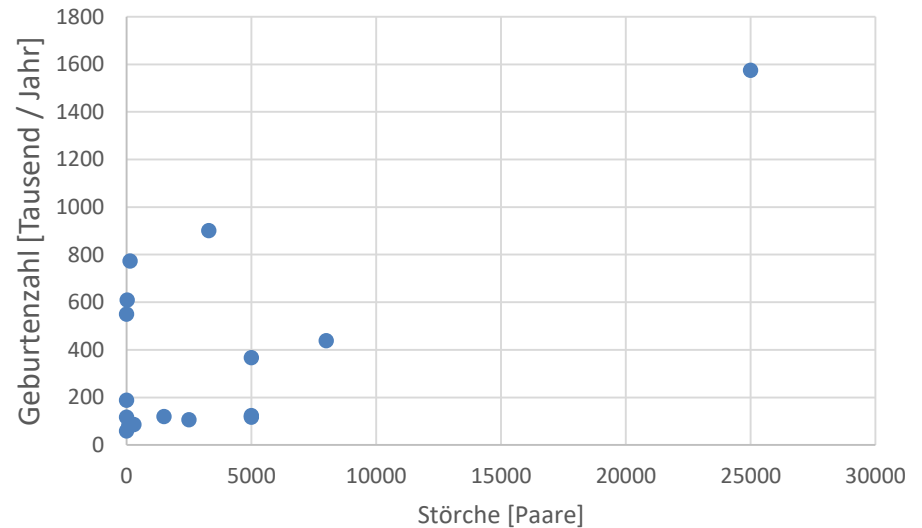
Zusammenhang und Unabhängigkeit

- Sind X und Y unabhängig, dann gilt
 $Cov(x, y) = 0$ und damit auch $\rho_{x,y} = 0$
- Gilt das umgekehrt auch, also wenn $\rho_{x,y} = 0$ dann sind X und Y unabhängig?
Nein! Zum Beispiel sind X und $Y=X^2$ unkorreliert, aber nicht unabhängig
- Die logisch korrekte Umkehrung gilt aber, d.h. wenn $\rho_{x,y} \neq 0$ dann sind X und Y auch nicht unabhängig.
- Gilt dann auch, dass bei einer Korrelation, d.h. einem statistischen Zusammenhang auch immer ein kausaler Zusammenhang, d.h. eine Ursache-Wirkung Beziehung gilt?

Gibt es einen Zusammenhang zwischen der Anzahl der Störche und der Anzahl der Geburten?

R. Matthews, Storks Deliver Babies (p=0.008)

| Land | Störche [Paare] | Geburtenzahl [Tausend / Jahr] |
|---------------|-----------------------------|----------------------------------|
| Albania | 100 | 83 |
| Austria | 300 | 87 |
| Belgium | 1 | 118 |
| Bulgaria | 5000 | 117 |
| Denmark | 9 | 59 |
| France | 140 | 774 |
| Germany | 3300 | 901 |
| Greece | 2500 | 106 |
| Holland | 4 | 188 |
| Hungary | 5000 | 124 |
| Italy | 5 | 551 |
| Poland | 30 | 610 |
| Portugal | 1500 | 120 |
| Romania | 5000 | 367 |
| Spain | 8000 | 439 |
| Switzerland | 150 | 82 |
| Turkey | 25000 | 1576 |
| Korrelationen | Störche und Geburtenzahl | 0,72 |



Gibt es einen Zusammenhang zwischen der Anzahl der Störche und der Anzahl der Geburten?

Ja, aber ...

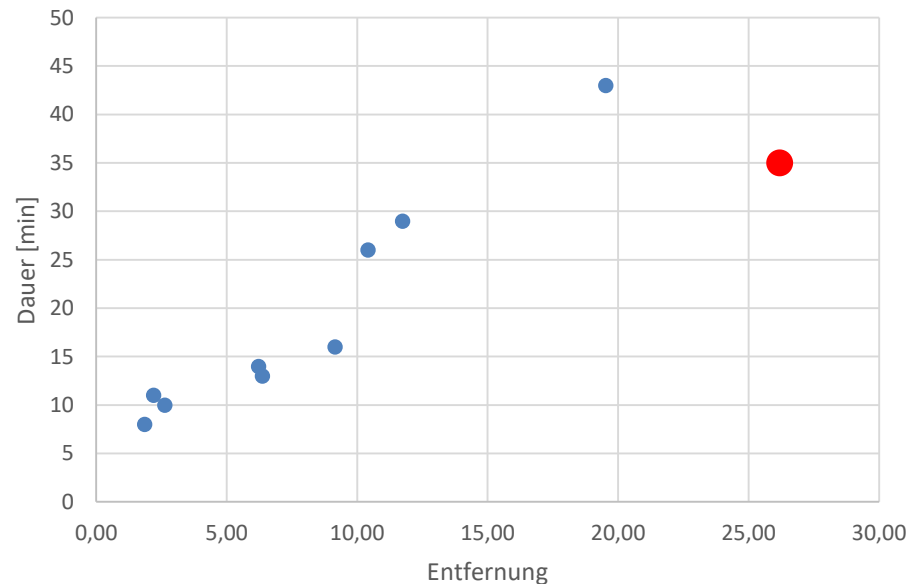
Statistische und kausale Zusammenhänge

1. Ein statistischer Zusammenhänge hat eine kausale Ursache.

Bsp: Je länger die zurückgelegte Entfernung, desto länger die dafür benötigte Zeit (bei gleicher Fortbewegungsart).

Entfernung = Geschwindigkeit * Dauer

Dauer = $1/\text{Geschwindigkeit} * \text{Entfernung}$



Statistische und kausale Zusammenhänge

1. Ein statistischer Zusammenhänge hat eine kausale Ursache.

Bsp: Je länger die zurückgelegte Entfernung, desto länger die dafür benötigte Zeit (bei gleicher Fortbewegungsart).

2. Ein statistischer Zusammenhang hat keine kausale Ursache, sog. Scheinkorrelation

Statistische und kausale Zusammenhänge

1. Ein statistischer Zusammenhänge hat eine kausale Ursache.

Bsp: Je länger die zurückgelegte Entfernung, desto länger die dafür benötigte Zeit (bei gleicher Fortbewegungsart).

2. Ein statistischer Zusammenhang hat keine kausale Ursache, sog. Scheinkorrelation

- a) Konfundierende Variable, d.h. es gibt eine zugrundeliegende Ursache die einen statistischen Zusammenhang zwischen beiden Merkmalen herstellt.

Bsp.: Zahl der Störche und Zahl der Geburten

Statistische und kausale Zusammenhänge

1. Ein statistischer Zusammenhänge hat eine kausale Ursache.

Bsp: Je länger die zurückgelegte Entfernung, desto länger die dafür benötigte Zeit (bei gleicher Fortbewegungsart).

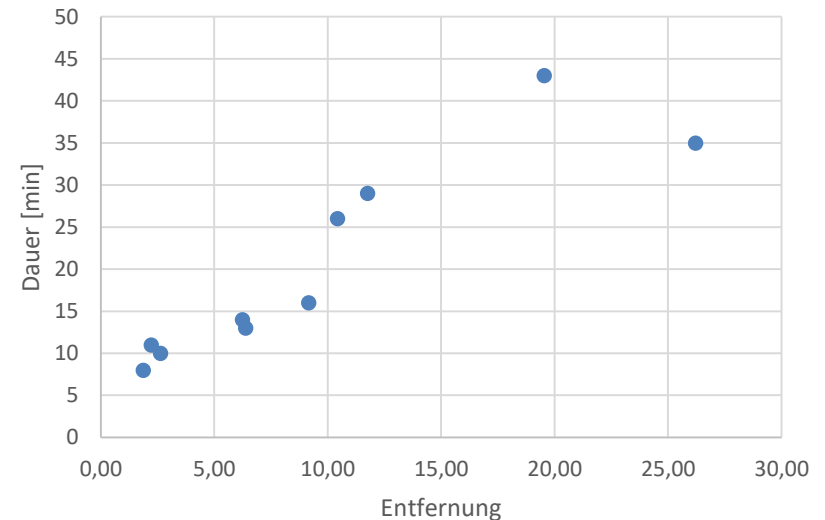
2. Ein statistischer Zusammenhang hat keine kausale Ursache, sog. Scheinkorrelation

- a) Konfundierende Variable, d.h. es gibt eine zugrundeliegende Ursache die einen statistischen Zusammenhang zwischen beiden Merkmalen herstellt.
Bsp.: Zahl der Störche und Zahl der Geburten
- b) Explizite (bewusste) oder implizite (zufällige) Datenselektion, d.h. der Zusammenhang ist nur auf einer speziell ausgewählten Teilmenge gültig


Datenpaare – Beispiel Car-Sharing

| | Entfernung | Dauer_min |
|---------------------|------------|-----------|
| M =MITTELWERT | 9,64 | 20,5 |
| S =STABW.N | 7,51 | 11,38 |
| | | |
| Cov =KOVARIANZ.P | 77,52 | |
| Cor =KORREL | 0,91 | |
| Rang-Cor | 0,96 | |

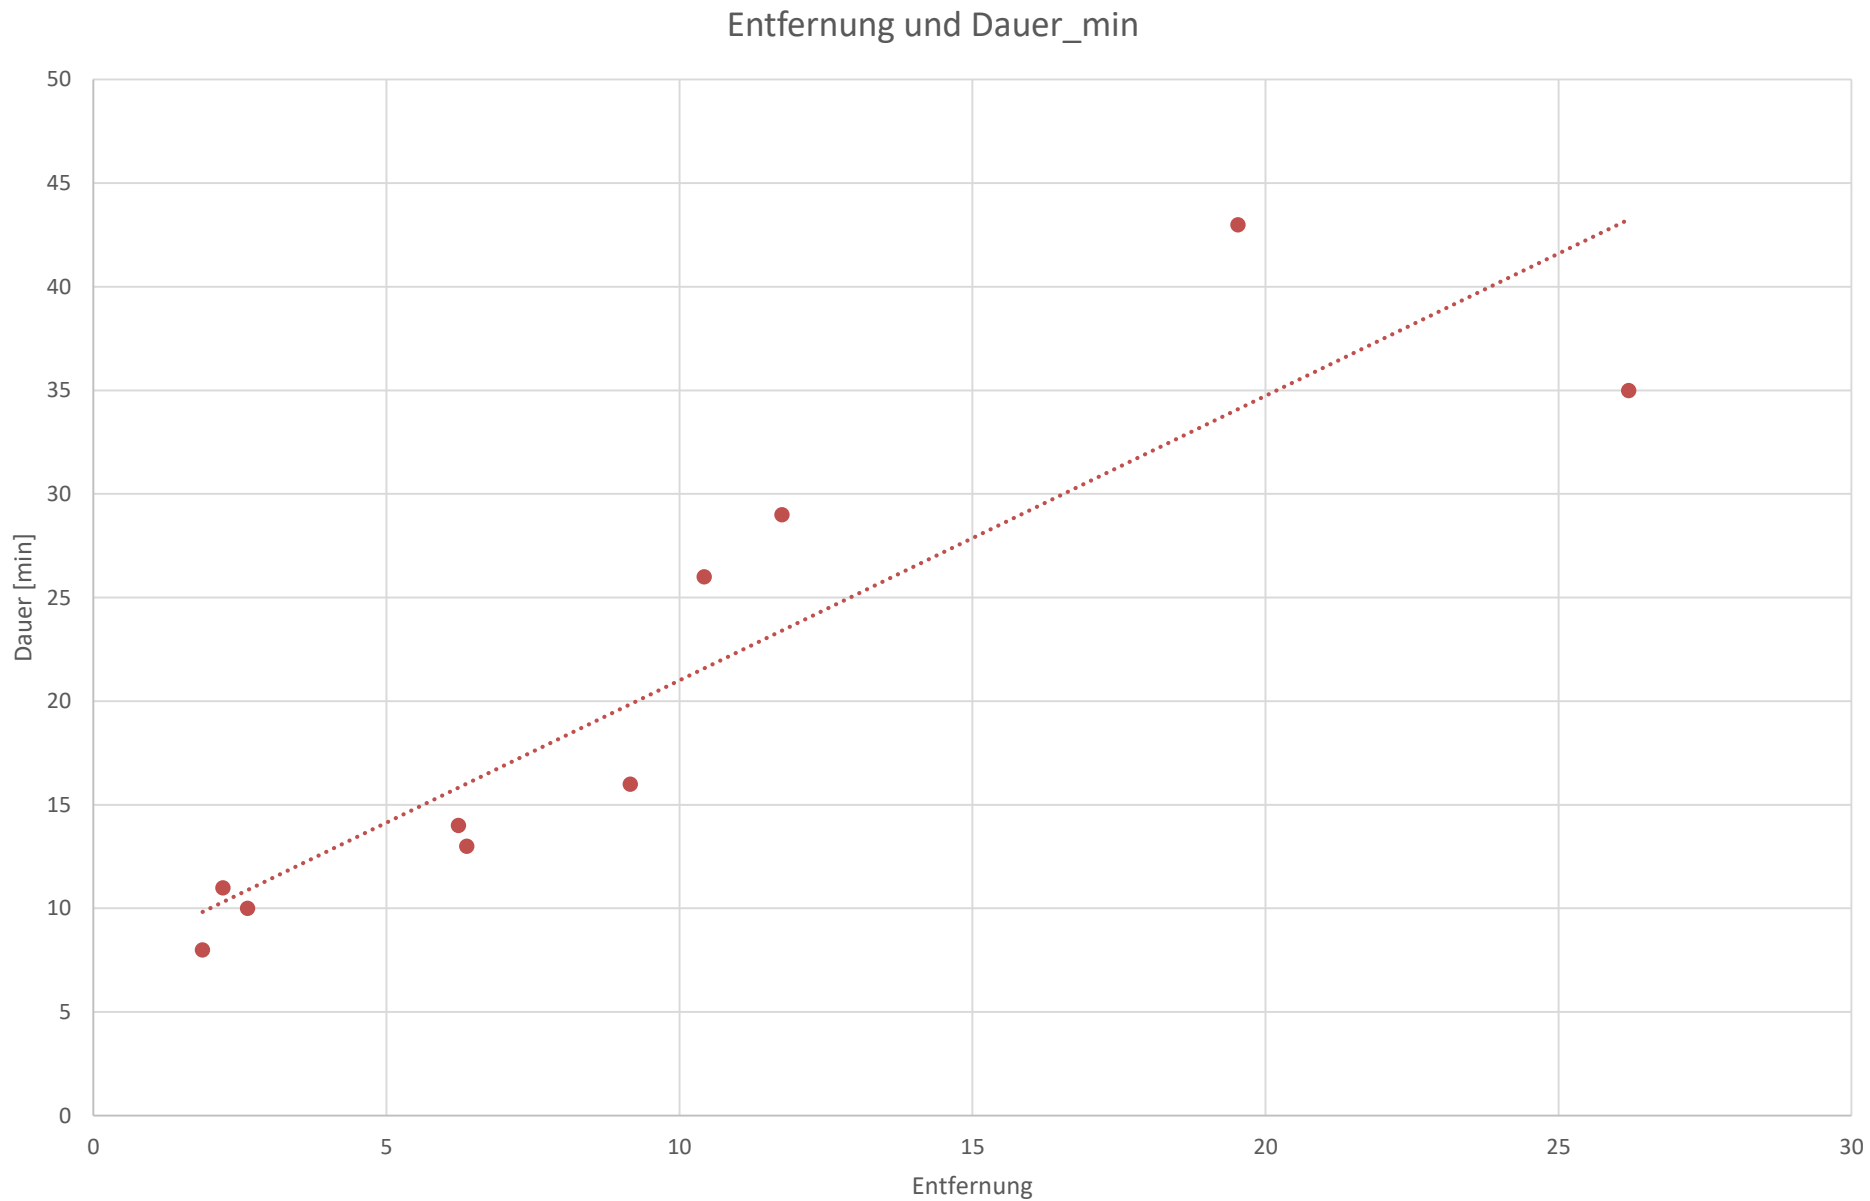
| Entfernung | Dauer_min |
|--------------|-------------|
| 1,86 | 8 |
| 2,21 | 11 |
| 19,53 | 43 |
| 26,20 | 35 |
| 2,63 | 10 |
| 6,23 | 14 |
| 6,37 | 13 |
| 9,16 | 16 |
| 10,42 | 26 |
| 15,00 | ???? |



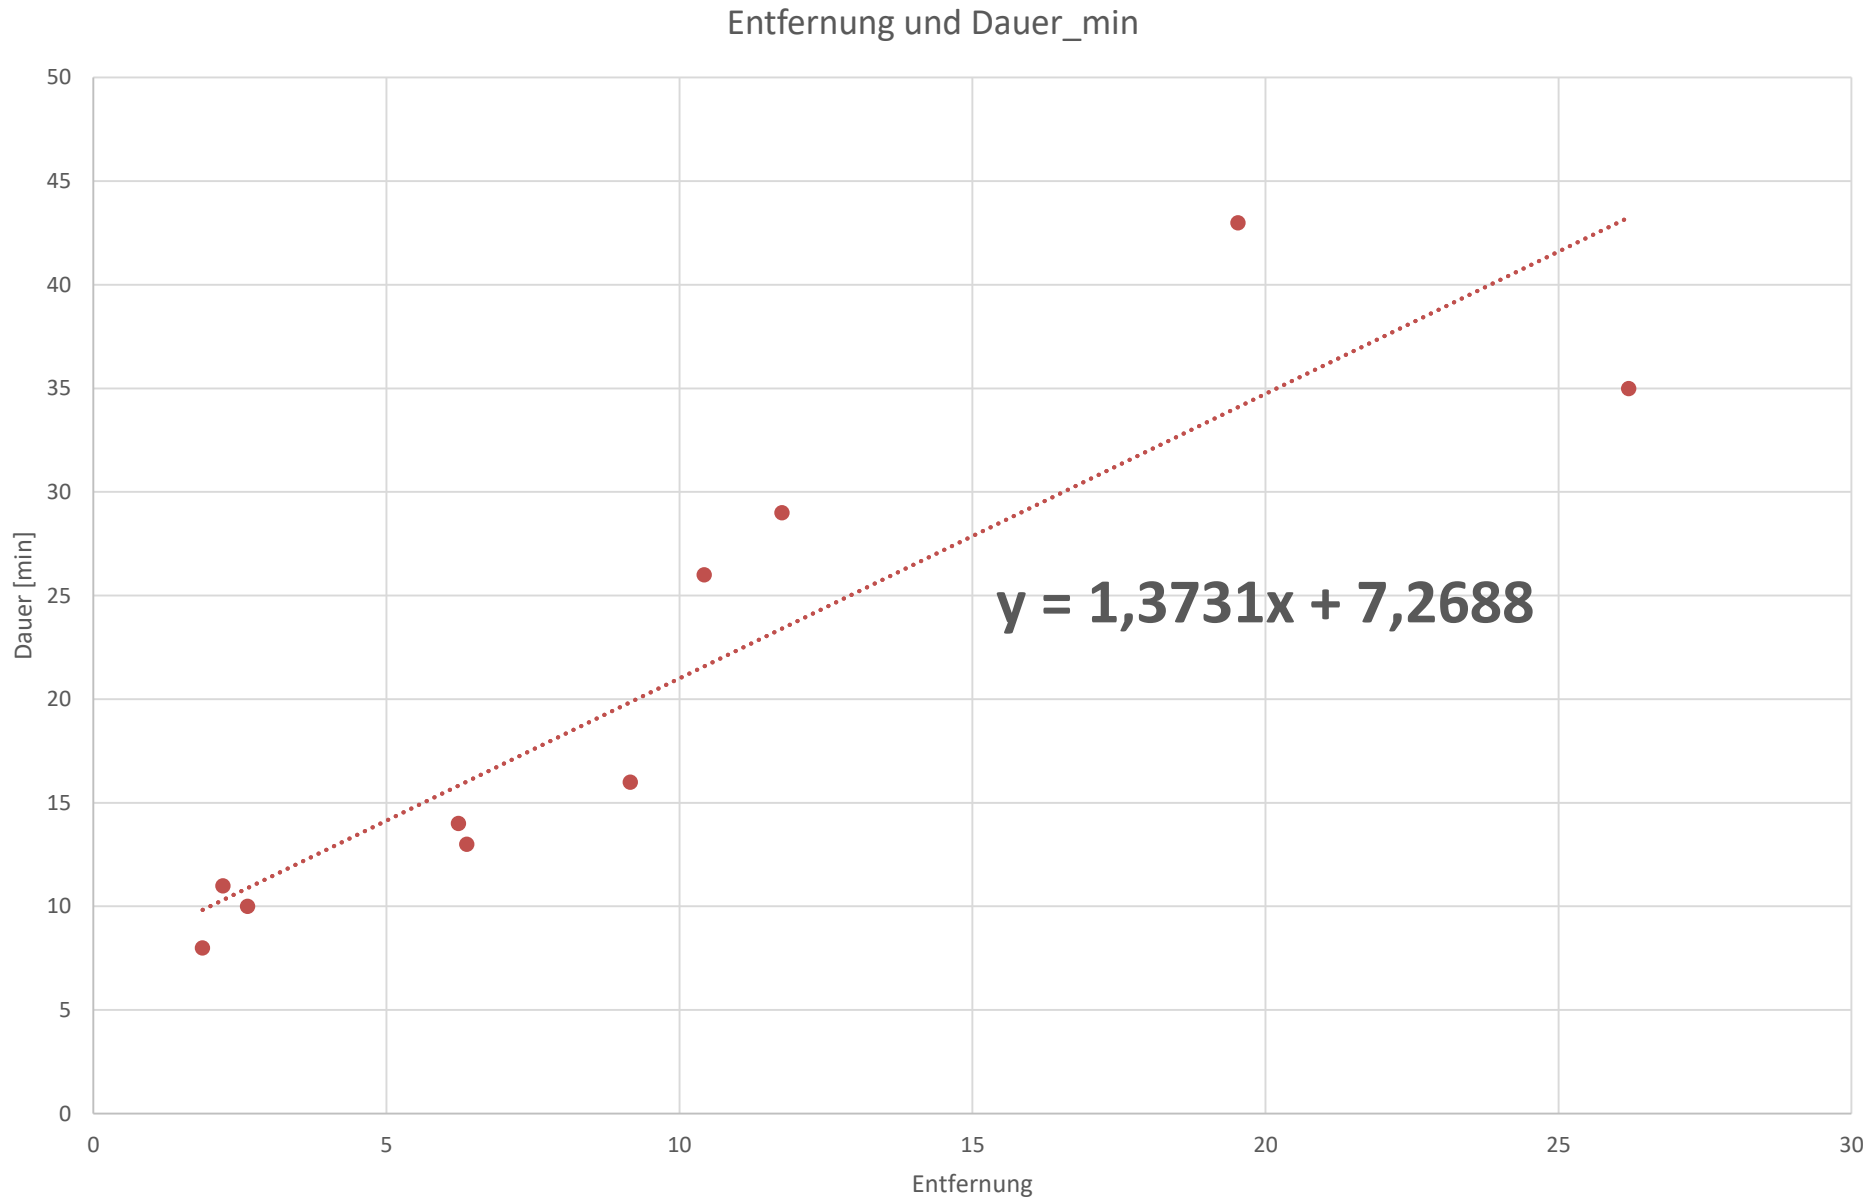
Streudiagramm (XY-Plot)



Streudiagramm mit Trendlinie



Streudiagramm mit Trendlinie



- AB hier nicht mehr gezeigt!!!

Lineare Regression

- Lineare Regression liefert Prognose

$$\hat{y} = \hat{y}(x) = a x + b$$

- Parameter

- a: Steigung
- b: Achsenabschnitt

- Wie bestimmt man a und b?

- Quadratische Abweichung = Fehler der Prognose

$$\sum_{i=1}^n (y_i - \hat{y}(x_i))^2 = \sum_{i=1}^n (y_i - (a x_i + b))^2$$

(mean squared error - mse)

- Ziel: Minimierung des Prognosefehlers

(kleinste-Quadrate-Regression, least-squares-regression)

Lineare Regression

$$L(a, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (a x_i + b))^2$$

$$1. \quad \frac{\partial L(a, b)}{\partial b} = 0$$

$$b = \bar{y} - a \cdot \bar{x}$$


$$2. \quad \frac{\partial L(a, b)}{\partial a} = 0$$

$$a = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

Datenpaare – Beispiel Car-Sharing

| | Entfernung | Dauer_min |
|---------------------|------------|-----------|
| M =MITTELWERT | 9,64 | 20,5 |
| S =STABW.N | 7,51 | 11,38 |
| Cov =KOVARIANZ.P | 77,52 | |
| Cor =KORREL | 0,91 | |
| Rang-Cor | 0,96 | |

| Entfernung | Dauer_min |
|------------|-----------|
| 1,86 | 8 |
| 2,21 | 11 |
| 19,53 | 43 |
| 26,20 | 35 |
| 2,63 | 10 |
| 6,23 | 14 |
| 6,37 | 13 |
| 9,16 | 16 |
| 10,42 | 26 |
| 11,75 | 29 |



Lineare Regression

- Lineare Regression liefert Prognose

$$\hat{y} = \hat{y}(x) = a x + b$$

- Wie gut ist die Prognose?

- Mittlere Quadratische Abweichung = Fehler der Prognose

$$mse(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}(x_i))^2$$

- Fehler der Prognose mit Mittelwert = Varianz

$$mse(y, \bar{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = s_G^2(y)$$

- Bestimmtheitsmaß R^2

$$R^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2 - \sum_{i=1}^n (y_i - \hat{y}(x_i))^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{mse(y, \hat{y})}{mse(y, \bar{y})}$$

**Relativer Rückgang
des Fehlers**

$$= \frac{s_G^2(y) - s_G^2(y - \hat{y})}{s_G^2(y)} = 1 - \frac{s_G^2(y - \hat{y})}{s_G^2(y)}$$

**Erklärte Varianz =
Relativer Rückgang
der Varianz**

$$= \rho_{x,y}^2$$

Quadrierte Korrelation

Datenpaare – Beispiel Car-Sharing

| | Entfernung | Dauer_min |
|---------------------|------------|-----------|
| M =MITTELWERT | 9,64 | 20,5 |
| S =STABW.N | 7,51 | 11,38 |
| Cov =KOVARIANZ.P | 77,52 | |
| Cor =KORREL | 0,91 | |
| Rang-Cor | 0,96 | |

| Entfernung | Dauer_min |
|------------|-----------|
| 1,86 | 8 |
| 2,21 | 11 |
| 19,53 | 43 |
| 26,20 | 35 |
| 2,63 | 10 |
| 6,23 | 14 |
| 6,37 | 13 |
| 9,16 | 16 |
| 10,42 | 26 |
| 11,75 | 29 |

