

Maschinelles Lernen

Univariate Lineare Regression und einfacher Gradientenabstieg

Prof. Dr. Rainer Stollhoff

Supervised Learning

Supervised Learning

1. Aufgabe A

Vorhersage $\hat{Y} = A(X)$

2. Qualität Q

Verlustfunktion $L(\hat{Y}, Y)$

3. Erfahrung E


Datensatz

(x_i, y_i) für $i = 1, \dots, n$

4. Maschine

Eine Maschine **lernt** aus Erfahrung E eine Aufgabe A mit der Qualität Q, wenn die Qualität Q beim erfüllen der Aufgabe A mit Erfahrung E steigt (T. Mitchell, MIT, 1988)

Einfache univariate Regression



- **Aufgabe**
sage anhand von x den Zielwert y vorher

$$\hat{y} = f(x)$$


- **Erfahrung**
Beobachtungen: (x_i, y_i)

- **Qualität**
sage den Zielwert möglichst gut vorher

Gleichheit: $\hat{y} == y$

Abstand: $(\hat{y} - y)^2$

Einfache univariate Regression



- **Aufgabe**
sage anhand von x den Zielwert y vorher

$$\hat{y} = \hat{y}(x) = f(x)$$

- **Erfahrung**
Beobachtungen: (x_i, y_i)


- **Qualität**
sage den Zielwert möglichst gut vorher

Gleichheit: $\hat{y} == y$

Abstand: $(\hat{y} - y)^2$

- **Maschine bzw. Modell**
Look-up-table: $\hat{y}(x) = y_i$ für $x = x_i$, \bar{y} sonst
Lineares Modell: $\hat{y} = \theta \cdot x$

Einfache univariate Regression



- **Aufgabe**
sage anhand von x den Zielwert y vorher
$$\hat{y} = \hat{y}(x) = f(x)$$
- **Erfahrung**
Beobachtungen: (x_i, y_i)
- **Qualität**
sage den Zielwert möglichst gut vorher
Gleichheit: $\hat{y} == y$
Abstand: $(\hat{y} - y)^2$
- **Maschine bzw. Modell**
Look-up-table: $\hat{y}(x) = y_i$ für $x = x_i$, \bar{y} sonst
Lineares Modell: $\hat{y} = \theta \cdot x$

Einfache univariate Regression – analytische Lösung

Aufgabe: Regression, d.h. Vorhersage $\hat{y} = \hat{y}(x) = f(x)$

Erfahrung: Datensatz $(x_i, y_i)_{i=1}^n$

Qualität: Quadratische Verlustfunktion

$$L(y, \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - f(x_i; \theta))^2 = L(\theta)$$

Maschine: vereinfachte lineare Regression mit

$$f(x; \theta) = \theta \cdot x$$

Lernen: Finde einen Wert für θ , der die quadratische Verlustfunktion minimiert

Analytisch über die Nullstelle der ersten Ableitung

$$\frac{d}{d\theta} L(\theta) = \frac{d}{d\theta} \sum_{i=1}^n (y_i - f(x_i; \theta))^2 = \frac{d}{d\theta} \sum_{i=1}^n (y_i - x_i \cdot \theta)^2 = \sum_{i=1}^n 2 \cdot (y_i - x_i \cdot \theta) \cdot (-x_i) = 0$$

$$\theta_{opt} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} = \frac{Cov(x, y)}{Var(x)}$$

Einfache univariate Regression – Gradientenabstieg

Aufgabe: Regression, d.h. Vorhersage $\hat{y} = \hat{y}(x) = f(x)$

Erfahrung: Datensatz $(x_i, y_i)_{i=1}^n$


Qualität: Quadratische Verlustfunktion

$$L(y, \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - f(x_i; \theta))^2 = L(\theta)$$

Maschine: vereinfachte lineare Regression mit

$$f(x; \theta) = \theta \cdot x$$

Lernen: Finde einen Wert für θ , der die quadratische Verlustfunktion minimiert



Startwert $\theta_0 = 0$ $L(\theta_0)$ $L'(\theta_0)$

$\theta_1 = \theta_0 + \alpha \cdot L'(\theta_0)$ mit $\alpha = -1$

$\theta_2 = \theta_1 + \alpha \cdot L'(\theta_1)$

.....

$\theta_{opt} = \theta_{\epsilon} + \alpha \cdot 0$

Einfache univariate Regression – analytische Lösung

Aufgabe: Regression, d.h. Vorhersage $\hat{y} = \hat{y}(x) = f(x)$

Erfahrung: Datensatz $(x_i, y_i)_{i=1}^n$

Qualität: Quadratische Verlustfunktion

$$L(y, \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - f(x_i; \theta))^2 = L(\theta)$$

Maschine: vereinfachte lineare Regression mit

$$f(x; \theta) = \theta \cdot x$$

Lernen: Finde einen Wert für θ , der die quadratische Verlustfunktion minimiert

Durch geeignete Wahl von θ in einem iterativen Prozess (Gradientenabstiegsverfahren):

1. Wähle Startwert z.B. $\theta^0 = 0$
2. Berechne Ableitung $\frac{d}{d\theta} L(\theta) = \frac{d}{d\theta} \sum_{i=1}^n (y_i - f(x_i; \theta))^2 = \frac{d}{d\theta} \sum_{i=1}^n (y_i - x_i \cdot \theta)^2$

$$= \sum_{i=1}^n 2 \cdot (y_i - x_i \cdot \theta) \cdot (-x_i)$$
3. Update $\theta^{t+1} = \theta^t + \alpha \cdot \frac{d}{d\theta} L(\theta^t) = \theta^t - \alpha \cdot 2 \sum_{i=1}^n (y_i - x_i \cdot \theta^t) \cdot x_i = \theta^t + 2 \sum_{i=1}^n (y_i - x_i \cdot \theta^t) \cdot x_i$
mit $\alpha = -1$ (steilster Abstieg)