

Maschinelles Lernen

Modellselektion und -validierung

Prof. Dr. Rainer Stollhoff

Übersicht

- Motivation
- Bias-Varianz-Zerlegung
- Regularisierung in der Modellselektion
- Resampling in der Modellvalidierung

Motivation: Polynominterpolation

Aufgabe: Regression, d.h. Vorhersage $\hat{y} = \hat{y}(x) = f(x)$

Erfahrung: Datensatz $(x_i, y_i)_{i=1}^n$

Qualität: Verlustfunktion: $L(y, \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - f(x_i; \theta))^2 = L(\theta)$

Maschine: Regression mit $f(x; \theta_1, \dots, \theta_m) = \theta_0 + \theta_1 \cdot x + \theta_2 \cdot x^2 + \dots + \theta_m \cdot x^m$

Lernen: Finde Werte für $\theta = (\theta_1, \dots, \theta_m)$, die die quadratische Verlustfunktion minimieren



Polynominterpolation:

Falls $m \geq n$ gibt es immer Werte für θ so dass $f(x_i; \theta) = y_i$ und damit $L(\theta) = 0$

$$\text{mit } \ell_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j} = \frac{x - x_0}{x_i - x_0} \dots \frac{x - x_{i-1}}{x_i - x_{i-1}} \cdot \frac{x - x_{i+1}}{x_i - x_{i+1}} \dots \frac{x - x_n}{x_i - x_n}$$

$$\text{definiere } f(x) = \sum_{i=1}^n y_i \ell_i(x)$$

Motivation: Overfitting der Trainingsdaten



Bias-Varianz-Zerlegung des Vorhersagefehlers

- Bestmögliche Vorhersage
 - Vorhersage $y = f(x) + \epsilon$ dabei $f(x)$ als bestmögliche Vorhersage und ϵ als echter Zufallswert
 - Unvermeidbarer Fehler $E_{y,x}[(y - f(x))^2]$
- Bestmögliches geschätztes Modell
 - Vorhersage $\hat{f}(x)$ minimiert $(f(x) - \hat{f}(x))^2$ über x
 - Bias des Modells $E_x[(f(x) - \hat{f}(x))^2]$
- Bestmögliches auf einem Trainingsdatensatz geschätztes Modell
 - Trainingsdatensatz $T = (x_i, y_i)$ für $i = 1, \dots, n$
 - Vorhersage $\hat{y} = \hat{f}(x; T)$ minimiert $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$
 - Varianz der Vorhersagen $E_{x,T}[(\hat{f}(x) - \hat{f}(x; T))^2]$

- Bias-Varianz-Zerlegung

$$E_{y,x}[(y - \hat{f}(x))^2] = E_{y,x}[(y - f(x))^2] + E_x[(f(x) - \hat{f}(x))^2] + E_{x,T}[(\hat{f}(x) - \hat{f}(x; T))^2]$$

Vorhersagefehler = Unvermeidbarer Fehler + Bias + Varianz

- Motivation
- Bias-Varianz-Zerlegung
- **Regularisierung in der Modellselektion**
 - Ziel: Reduktion der Modellkomplexität und damit Verringerung der Varianz
- Resampling in der Modellvalidierung

Bias-Varianz-Zerlegung des Vorhersagefehlers

Unvermeidbarer Fehler

$$E_x[(y - f(x))^2]$$

Bias des Modells



$$E_x[(f(x) - \hat{f}(x))^2]$$

Varianz der Vorhersagen

$$E_{x,T}[(\hat{f}(x) - \hat{f}(x;T))^2]$$

Vorhersagefehler

$$E_x[(y - \hat{f}(x))^2]$$



Hoher Bias
Geringe Varianz

Geringer Bias
Hohe Varianz



Methoden der Regularisierung in der Modellselektion

- Regularisierungsterm in der Verlustminimierung für parametrisches Modell mit $\theta = (\theta_1, \dots, \theta_m)$
 - Tikhonov Regularization / Ridge Regression:
 - $L(\theta; \lambda) = \sum_{i=1}^n (y_i - f(x_i; \theta))^2 + \lambda \sum_{j=1}^m (\theta_j)^2$
 - Akaike Information Criterion:
 - $AIC(\theta) = -2 (\sum_i \log \hat{p}(y_i; x_i, \theta)) + 2 \cdot m$
 - Bayesian Information Criterion:
 - $BIC(\theta) = -2 (\sum_i \log \hat{p}(y_i; x_i, \theta)) + \ln(n) \cdot m$
- Early-Stopping, d.h. vorzeitiges Abbrechen der Optimierungsiterationen zum Beispiel
 - Begrenzen der Anzahl der aufeinanderfolgenden Splits bei Klassifikationsbäumen oder
 - Begrenzen der Anzahl der Boosting-Iterationen
- Feste Einschränkung der Modellkomplexität zum Beispiel
 - Beschränken des maximalen Grades einer polynomialen Funktion
 - Beschränken auf lineare Funktionen in der multivariaten Regression

Übersicht


- Motivation
- Bias-Varianz-Zerlegung
- Regularisierung in der Modellselektion
- **Resampling in der Modellvalidierung**
 - Ziel: Verlässlichere Schätzung des Vorhersagefehlers

Bias-Varianz-Zerlegung des Vorhersagefehlers




Sampling zur Modellvalidierung

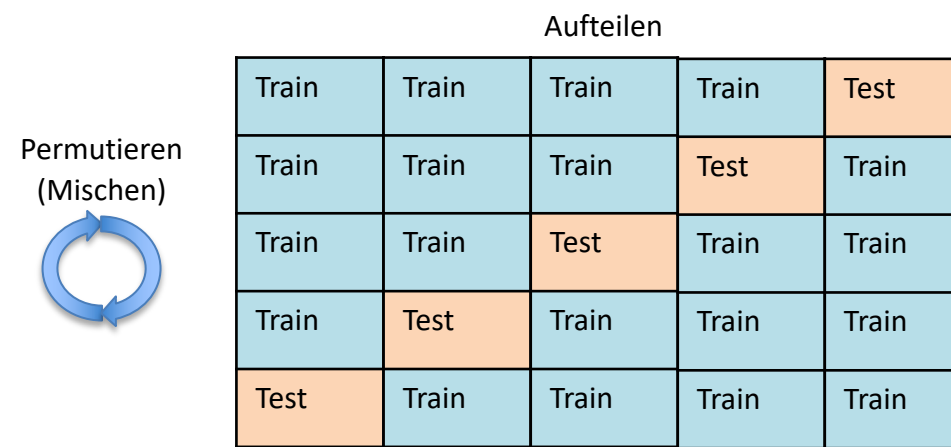
Festes Holdout




Zufälliges Holdout



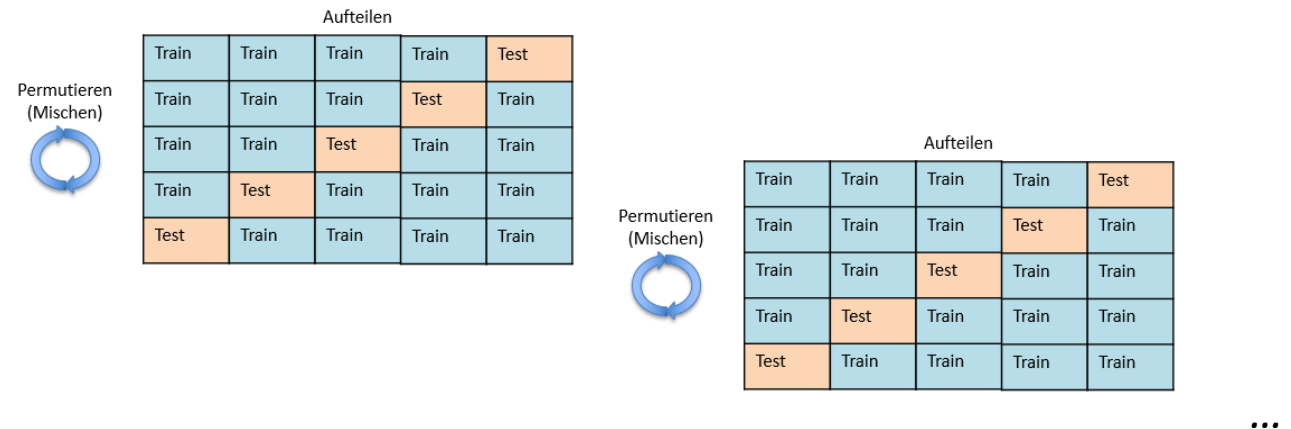
Kreuzvalidierung



Wiederholtes zufälliges Holdout



Wiederholte Kreuzvalidierung



Leave-One-Out Kreuzvalidierung

Training auf $n-1$ Daten, Test auf Restbeobachtung